당뇨 예측 모델 보고서

작성자 : 김택권

1. 한 줄 요약

- 우리 팀은 건강검진 데이터로 “당뇨 위험”을 예측하는 AI 모델을 만들었습니다.
- 혈당 정보를 같이 넣으면 성능이 더 좋아졌습니다.
- 앱에서는 모든 컬럼이 필요하지 않고, 핵심 입력만 받으면 됩니다.

---

2. 우리가 푼 문제

질문	답
무엇을 예측?	당뇨인지 아닌지(2가지 분류)
데이터는?	KNHANES 2019 (`HN19_ALL.sav`)
대상 나이	만 19세 이상
정답 라벨	`HE_DM_HbA1c` 값으로 당뇨/비당뇨 구분

데이터 원본 출처

항목	내용
데이터명	국민건강영양조사(KNHANES) 제8기 (2019-2021) 원시자료 중 2019 데이터
원본 파일	`HN19_ALL.sav`
출처 기관	질병관리청(KDCA) 국민건강영양조사
프로젝트 내 보관 경로	`fastapi/resources/data/HN19_ALL.sav`
참고 문서	`국민건강영양조사+제8기(2019-2021)+원시자료+이용지침서.pdf`

왜 이 데이터를 사용했나?

이유	설명
신뢰도 높은 국가 데이터	국가 단위 건강조사 데이터라 품질/신뢰도가 높음
당뇨 관련 변수 포함	나이, BMI, 허리둘레, 혈당 등 핵심 변수가 포함됨
한국인 대상 예측에 적합	한국인 표본 기반이라 국내 사용자 앱에 더 적합
문서화된 변수 체계	이용지침서가 있어 변수 해석과 재현이 용이함

정답(타겟) 만들기

원래 값	바꾼 값
1, 2	0 (비당뇨)
3	1 (당뇨)

---

3. 어떤 입력값(피처)을 썼나?

3-1. 기본 입력

컬럼	설명	앱에서 받는 값
`sex`	성별	성별
`age`	나이	나이
`HE_BMI`	비만도(BMI)	BMI
`HE_wc`	허리둘레	허리둘레
`HE_glu`	공복 혈당	혈당(선택)

3-2. 추가로 만든 값(파생 피처)

컬럼	만드는 방법	왜 만들었나?
`HE_whr`	허리둘레 / 키	체형 특징을 더 잘 반영
`HE_bmi_wc`	BMI × 허리둘레 비율	단일 지표보다 복합 정보 반영

3-3. 두 가지 실험

실험	포함 피처 수	특징
혈당 포함	7개	혈당까지 넣어서 예측
혈당 미포함	6개	혈당 없이도 예측 가능한지 확인

---

4. 데이터 전처리(데이터 정리) 과정

"전처리"는 모델이 잘 배우도록 데이터를 정리하는 과정입니다.

순서	한 일	설명
1	성인만 남김	19세 이상만 사용
2	라벨 변환	당뇨/비당뇨 2가지로 단순화
3	결측 처리	빈칸(결측값)을 보완
4	표준화	값 크기를 비슷한 기준으로 맞춤
5	파생 피처 추가	허리-키 비율 등 새 정보 생성
6	SMOTE	당뇨 데이터가 적을 때 균형 보정

표준화 vs 정규화, 왜 표준화를 선택했나?

방법	의미	이번 선택
정규화	값을 0~1 범위로 맞춤	미선택
표준화	평균 0, 표준편차 1로 맞춤	**선택**

선택 이유: 이번에 쓴 KNN 같은 모델은 거리 계산을 많이 쓰기 때문에, 표준화가 안정적이었습니다.

---

5. Train / Validation / Test 나누기

데이터 묶음	비율	역할
Train	70%	모델 학습
Validation	10%	기준점(임계값) 조정
Test	20%	최종 성능 평가

쉽게 말해,

- **Train**: 공부용
- **Validation**: 모의고사
- **Test**: 최종 시험

---

6. 어떤 모델을 비교했고, 왜 이 모델을 골랐나?

6-1. 비교한 모델

분류	모델
선형	LogisticRegression, SGDClassifier
트리/앙상블	RandomForest, GradientBoosting, AdaBoost
거리/마진	KNN, SVM
신경망	MLPClassifier

6-2. 최종 선택 결과

두 실험 모두 **KNN**이 가장 좋은 점수를 얻었습니다.

실험	최종 모델	핵심 하이퍼파라미터
혈당 포함	KNN	`n_neighbors=3`, `weights=distance`, `p=2`
혈당 미포함	KNN	`n_neighbors=3`, `weights=distance`, `p=2`

6-3. 하이퍼파라미터(세부 설정) 선택 과정

- 여러 값 조합을 자동으로 시험해보는 방식(Grid Search)으로 비교
- 점수 기준: `balanced_recall`
  (정확도 + 환자 잘 찾는 능력(Recall)을 같이 반영)

---

7. 성능 결과 (숫자)

7-1. 핵심 지표 비교

지표	혈당 포함	혈당 미포함
Accuracy	0.8368	0.6675
Precision	0.4516	0.2267
Recall	0.8284	0.6036
F1	0.5846	0.3296
ROC-AUC	0.8608	0.6565

7-2. 왜 Accuracy만 보면 안 되나?

의료 문제에서는 "진짜 환자를 놓치지 않는 것"이 중요합니다.
그래서 **Recall**을 특히 중요하게 봤습니다.

지표	의미	왜 중요한가
Accuracy	전체 정답 비율	참고용
Precision	당뇨라고 한 것 중 진짜 비율	경고 정확도
Recall	실제 당뇨를 얼마나 잘 찾는지	의료에서 매우 중요
F1	Precision/Recall 균형	종합 판단

---

8. Confusion Matrix(예측 결과 요약표)

실험	TN	FP	FN	TP
혈당 포함	880	170	29	140
혈당 미포함	731	348	67	102

해석:

- **FN(놓친 환자)**가 적을수록 의료에 유리합니다.
- 혈당 포함 모델이 FN이 더 적어서 더 안전한 편입니다.

---

9. 어떤 모델이 의료 문제에 더 맞나?

결론: **혈당 포함 KNN 모델**이 더 적합합니다.

이유:

1. Recall이 더 높음 (환자를 더 잘 찾음)
2. ROC-AUC가 더 높음 (전체 구분 능력이 좋음)
3. Confusion Matrix에서 FN이 더 적음 (놓치는 환자 감소)

---

10. 앱 구현 시 전체 컬럼이 다 필요한가?

결론: **아니요. 핵심 입력만 필요합니다.**

구분	항목	설명
앱에서 직접 입력	성별, 나이, 키, 몸무게, 허리둘레	사용자가 화면에서 직접 입력
앱에서 선택 입력	혈당	입력하면 혈당 포함 모델 사용
앱 내부 계산	BMI	키/몸무게로 앱에서 계산 후 서버 전송
서버 내부 계산	`HE_whr`	허리둘레/키 로 계산
서버 내부 계산	`HE_bmi_wc`	BMI × (허리둘레/100) 로 계산

---

11. 그림으로 보는 결과 (이미지 중심)

Figure 1. 테스트 지표 비교

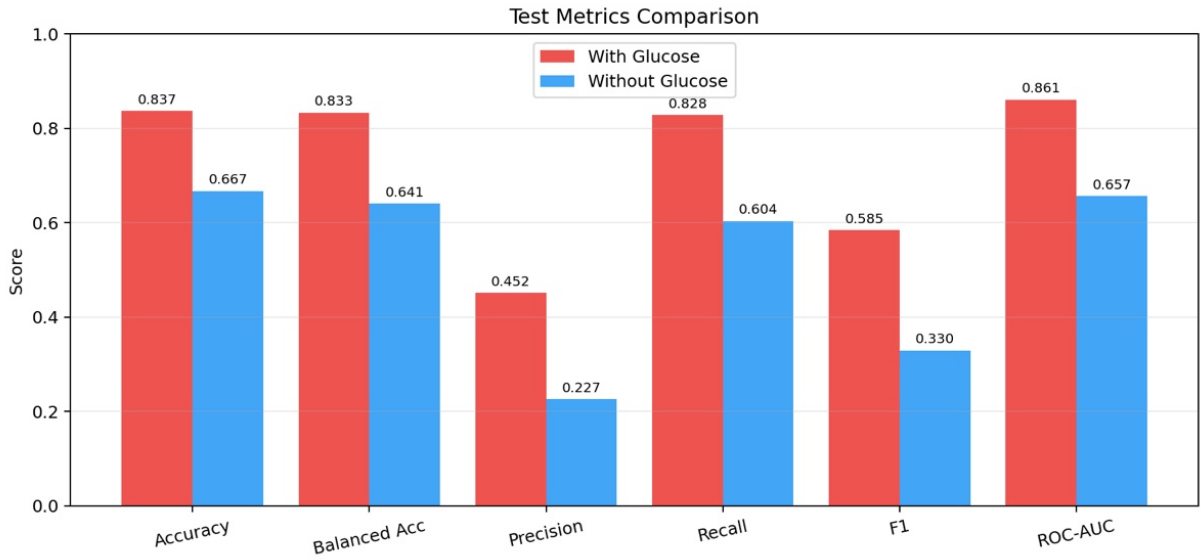

- 이 차트는 두 시나리오(혈당 포함/미포함)의 핵심 성능 지표를 한 번에 비교합니다.
- X축: 지표 종류(Accuracy, Precision, Recall, F1, ROC-AUC)
- Y축: 점수(0~1)
- 해석 포인트: 막대가 **높을수록 성능이 좋음**. 대부분 지표에서 혈당 포함 막대가 더 높습니다.

Figure 2. CV 점수 및 임계값 비교

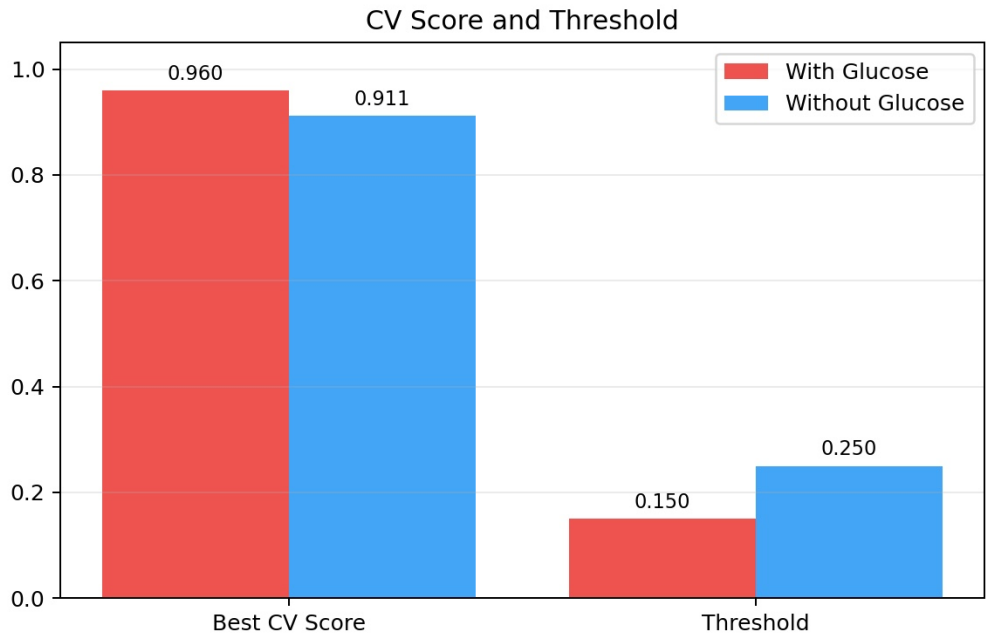

- 이 차트는 모델 선택에 사용된 교차검증 점수와 최종 임계값(threshold)을 비교합니다.
- X축: `Best CV Score`, `Threshold`
- Y축: 값(0~1)
- 해석 포인트: CV 점수는 **높을수록 좋고**, Threshold는 분류 경계값으로 높고 낮음 자체보다 운영 목적(민감도/정밀도)에 따라 의미가 달라집니다.

Figure 3. 레이더 차트(종합 성능)

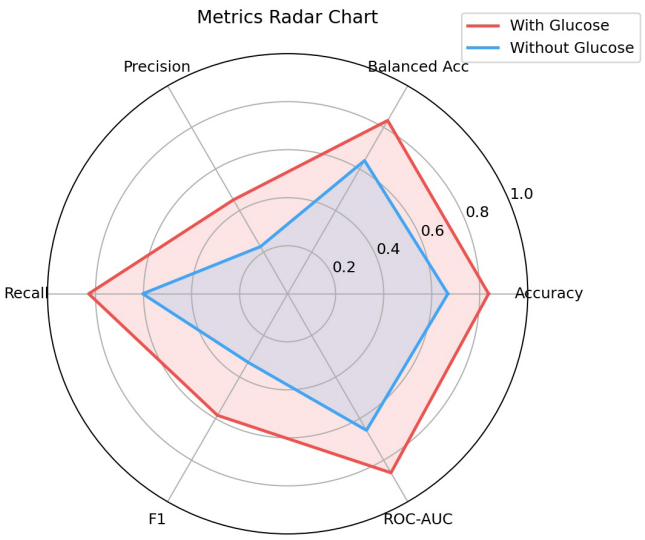

- 이 차트는 여러 지표를 원형으로 동시에 보여주는 종합 비교 그래프입니다.
- 각 축(방사형 축): Accuracy, Balanced Accuracy, Precision, Recall, F1, ROC-AUC
- 중심에서 바깥쪽으로 갈수록 점수가 큼(0→1)
- 해석 포인트: 면적이 넓고 바깥쪽일수록 전반 성능이 좋습니다. 혈당 포함 모델의 면적이 더 큽니다.

Figure 4. Confusion Matrix 비교

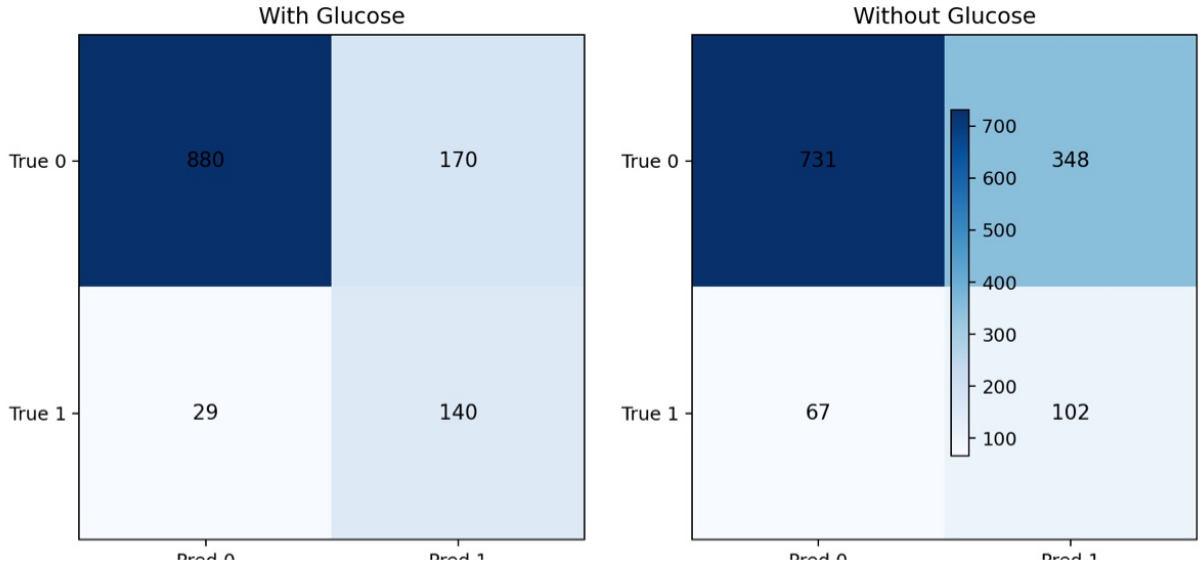

- 이 차트는 정답/오답을 2x2 표로 보여줍니다.
- X축: 모델 예측값(Pred 0, Pred 1), Y축: 실제값(True 0, True 1)
- 셀 의미: TN(정상 맞춤), FP(정상을 당뇨로 예측), FN(당뇨를 정상으로 놓침), TP(당뇨 맞춤)
- 해석 포인트: 의료 관점에서는 **FN이 낮을수록 유리**합니다. 혈당 포함 모델의 FN이 더 낮습니다.

Figure 5. ROC Curve 비교

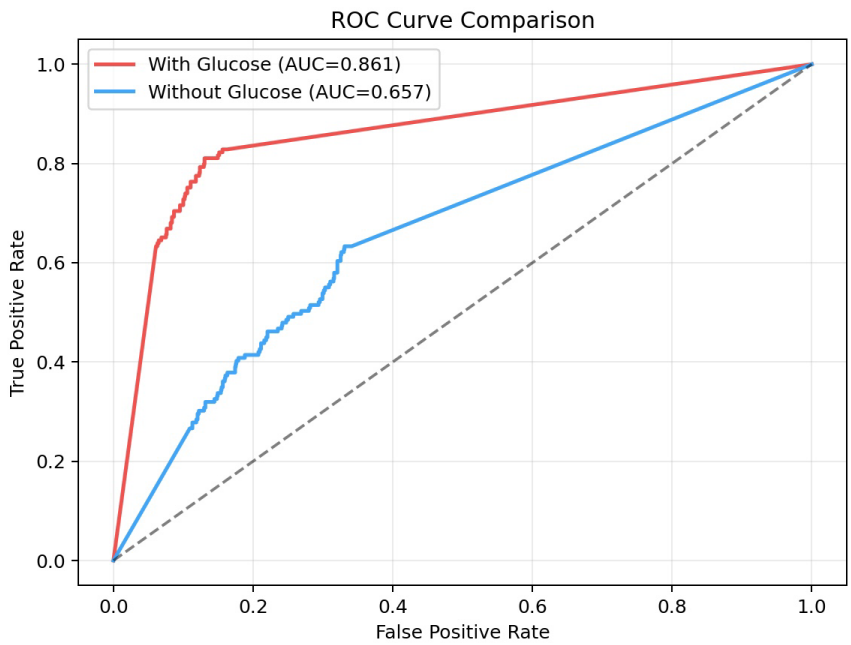

- 이 차트는 임계값을 바꿀 때 모델의 구분 능력이 어떻게 변하는지 보여줍니다.
- X축: FPR(False Positive Rate, 거짓 양성 비율)
- Y축: TPR(True Positive Rate, 실제 양성 탐지율 = Recall)

- 해석 포인트: 곡선이 **왼쪽 위에 가까울수록 좋고**, AUC 값이 **높을수록 좋습니다**.

Figure 6. 피처 수 비교

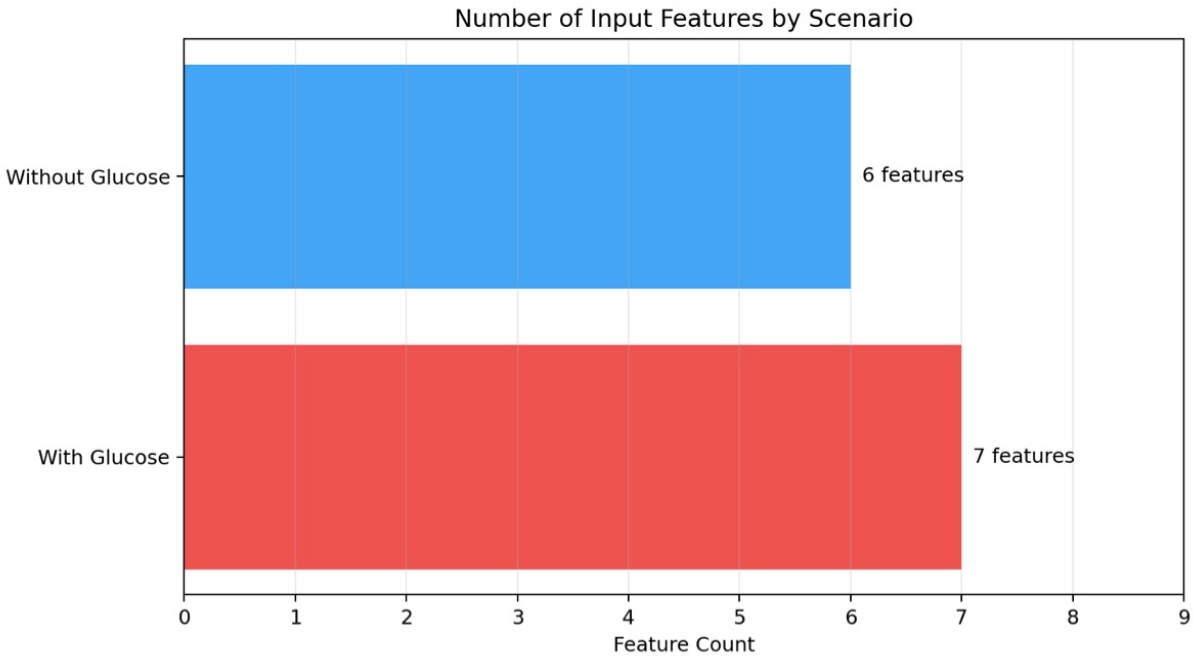

- 이 차트는 시나리오별 입력 피처 개수를 비교합니다.
- X축: 피처 개수
- Y축: 시나리오(혈당 포함/미포함)
- 해석 포인트: 혈당 포함 시나리오가 피처 1개(`HE_glu`) 더 많습니다.

Figure 7. Precision/Recall/F1 비교

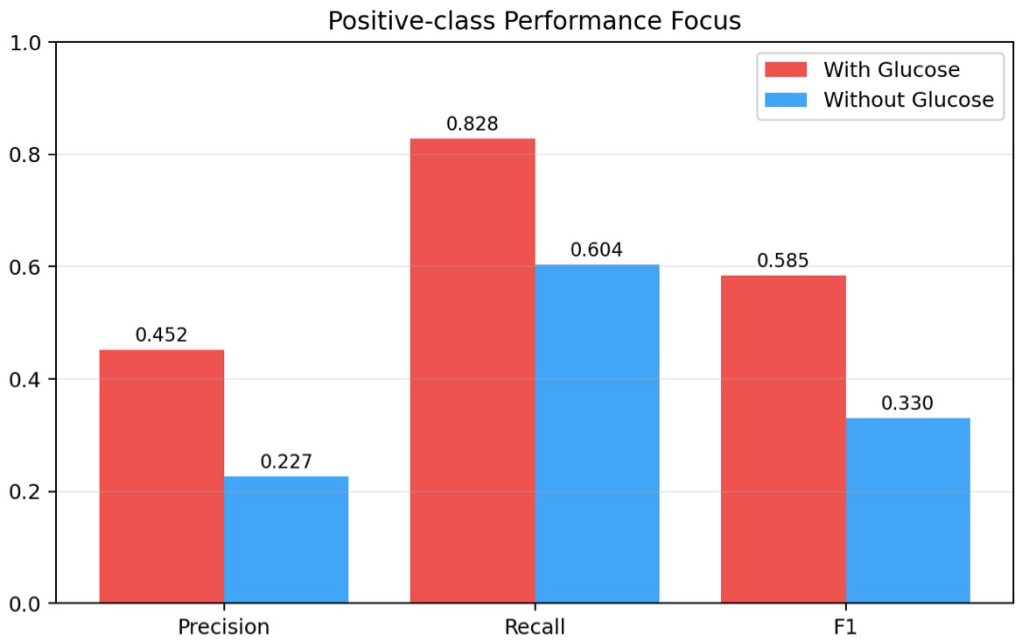

- 이 차트는 양성 클래스(당뇨) 중심 지표만 따로 비교합니다.
- X축: Precision, Recall, F1
- Y축: 점수(0~1)
- 해석 포인트: 막대가 **높을수록 좋음**. 특히 Recall 차이를 통해 환자 탐지 능력 차이를 확인할 수 있습니다.

Figure 8. 오류 유형(FP/FN) 비교

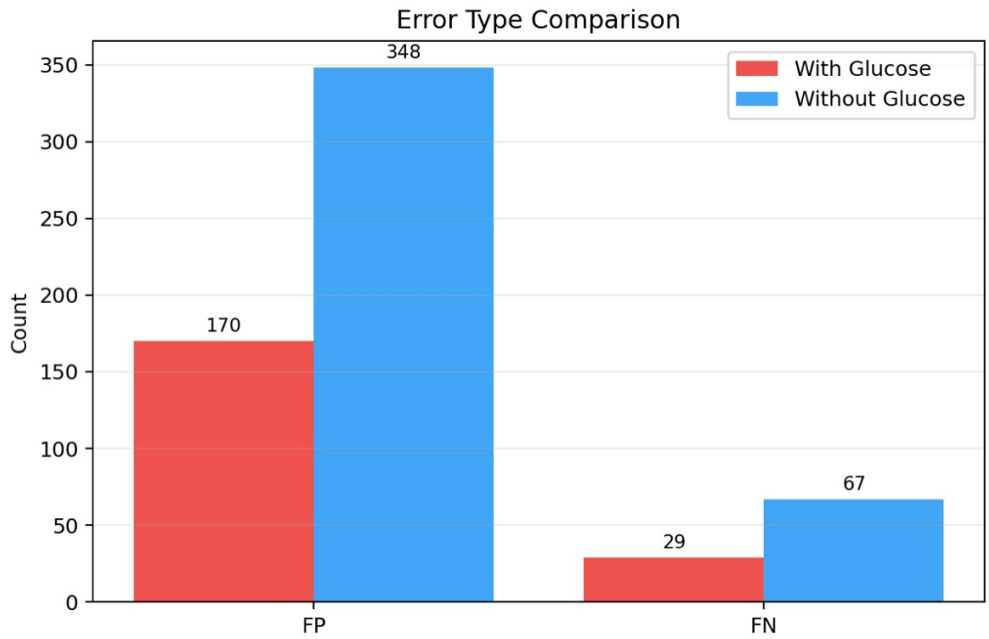

- 이 차트는 모델이 만든 두 가지 핵심 오류(FP, FN) 개수를 비교합니다.
- X축: 오류 유형(FP, FN)
- Y축: 오류 개수(건수)
- 해석 포인트: 의료 선별에서는 FN(환자 놓침)을 줄이는 것이 중요합니다. **막대가 낮을수록 더 바람직**합니다.

---

12. 재현(다시 실행) 방법

```
cd fastapi
source .venv/bin/activate

# 혈당 포함 모델 학습
python train_knhanes.py --with-glucose --feature-eng --poly --smote --score-by balanced_recall --save

# 혈당 미포함 모델 학습
python train_knhanes.py --feature-eng --poly --smote --score-by balanced_recall --save
```

데이터 파일 위치:

- `fastapi/resources/data/HN19_ALL.sav`