당뇨 예측 모델 보고서

작성자: 김택권

1. 한 줄 요약

- 우리 팀은 건강검진 데이터로 “당뇨 위험”을 예측하는 AI 모델을 만들었습니다.
- 기존 핵심 피처(`sex(성별)` , `age(나이)` , `HE_BMI(BMI)` , `HE_wc(허리둘레)` , `HE_glu(공복혈당)`)만으로도 실사용 가능한 성능을 확인했습니다.
- 추가 선택형 피처(F1~F2)는 별도 시뮬레이션 검증 후 앱/서버에 조건부 반영했으며, 성능 지표(Recall/FN/FP)는 지속 모니터링합니다.

---

2. 우리가 푼 문제

질문	답
무엇을 예측?	당뇨인지 아닌지(2가지 분류)
데이터는?	KNHANES 2019 (`HN19_ALL.sav`)
대상 나이	만 19세 이상
정답 라벨	`HE_DM_HbA1c(당뇨병 유병여부)` 값으로 당뇨/비당뇨 구분

데이터 원본 출처

항목	내용
데이터명	국민건강영양조사(KNHANES) 제8기 (2019-2021) 원시자료 중 2019 데이터
원본 파일	`HN19_ALL.sav`
출처 기관	질병관리청(KDCA) 국민건강영양조사
프로젝트 내 보관 경로	`fastapi/resources/data/HN19_ALL.sav`

참고 문서	국민건강영양조사+제8기(2019-2021)+원시자료+이용지침서.pdf

왜 이 데이터를 사용했나?

이유	설명
신뢰도 높은 국가 데이터	국가 단위 건강조사 데이터라 품질/신뢰도가 높음
당뇨 관련 변수 포함	나이, BMI, 허리둘레, 혈당 등 핵심 변수가 포함됨
한국인 대상 예측에 적합	한국인 표본 기반이라 국내 사용자 앱에 더 적합
문서화된 변수 체계	이용지침서가 있어 변수 해석과 재현이 용이함

정답(타겟) 만들기

원래 값	바꾼 값
1, 2	0 (비당뇨)
3	1 (당뇨)

---

3. 어떤 입력값(피처)을 썼나?

3-1. 기본 입력

컬럼(한글)	설명	앱에서 받는 값
`sex(성별)`	성별	성별
`age(나이)`	나이	나이
`HE_BMI(BMI)`	비만도(BMI)	BMI
`HE_wc(허리둘레)`	복부 비만 지표	허리둘레
`HE_glu(공복 혈당)`	공복 혈당	혈당(선택)

3-2. 추가로 만든 값(파생 피처)

컬럼(한글)	만드는 방법	왜 만들었나?
HE_whr(허리-신장 비율)	HE_wc(허리둘레) / HE_ht(키)	체형 특징을 더 잘 반영
HE_bmi_wc(BMI×허리 보정)	HE_BMI(BMI) × (HE_wc(허리둘레) / 100)	단일 지표보다 복합 정보 반영

3-3. 두 가지 실험

실험	포함 피처 수	특징
혈당 포함	7개	HE_glu(공복 혈당) 포함
혈당 미포함	6개	HE_glu(공복 혈당) 없이 예측

3-4. 원본(HN19_ALL.sav) 대비 단계별 데이터 규모

단계	조건	행 수(n)	잔존율(원본 대비)
원본	전체 레코드	8,110	100.0%
1차 필터	age(나이) >= 19	6,606	81.5%
2차 필터	HE_DM_HbA1c(당뇨 유병) ∈ {1,2,3}	5,914	72.9%
3차 필터	기본 피처 유효 (HE_BMI(BMI) , HE_wc(허리둘레) , HE_ht(키) > 0)	5,874	72.4%

3-5. 모델 입력 데이터프레임 info (핵심/확장 변수 결측 현황)

> 기준 데이터프레임: 3차 필터 후 n=5,874

변수	non-null	결측률
`sex(성별)`	5,874	0.00%
`age(나이)`	5,874	0.00%
`HE_BMI(BMI)`	5,874	0.00%
`HE_wc(허리둘레)`	5,874	0.00%
`HE_ht(키)`	5,874	0.00%
`HE_glu(공복 혈당)`	5,874	0.00%
`F1_family_dm(가족력)`	5,292	9.91%
`F2_htn_or_med(고혈압/혈압약)`	5,864	0.17%

> 참고: `HE_glu(공복 혈당)` 는 데이터셋 전체에는 고값(outlier)이 일부 존재하며, 앱 API에서는 입력 범위(44~~199)를 사용합니다.~~
> ~~기본 유효 표본 5,874건 중 앱 입력 범위(44~~199)에 해당하는 건수는 5,813건입니다.

3-6. 핵심 연속형 변수 describe (기본 유효 표본, n=5,874)

변수	mean	std	min	25%	50%(median)	75%	max
`age(나이)`	51.57	16.78	19.0	38.0	52.0	65.0	80.0
`HE_BMI(BMI)`	23.92	3.59	13.98	21.47	23.60	25.99	50.29
`HE_wc(허리둘레)`	83.97	10.41	53.0	76.6	83.8	90.8	135.9
`HE_ht(키)`	163.69	9.36	133.3	156.7	163.3	170.5	194.0
`HE_glu(공복 혈당)`	101.23	22.42	53.0	90.0	96.0	105.0	339.0

3-7. 기본 피처와 확장 후보 피처 비교 (사전 검증/조건부 반영 관점)

구분	변수(한글)	초기 모델(기본 피처)	확장 후보 검증	데이터 품질/관찰
핵심(기본)	`sex(성별)`, `age(나이)`, `HE_BMI(BMI)`, `HE_wc(허리둘레)`, `HE_glu(공복 혈당)`	사용	기준 피처로 유지	결측 낮고 안정적
확장 F1	`HE_DMfh1/2/3(가족 당뇨 진단력)`	조건부 사용(혈당 미입력 경로)	사전 검증 + 조건부 반영 완료	결측 약 9.9%, no_glu 경로에서 보조 피처 가치 확인

확장 F2	`DI1_dg`, `HE_HPdr`, `HE_HP` (고혈압/혈압약)	조건부 사용(우선 반영)	사전 검증 + 조건부 반영 완료	결측 매우 낮음, binned/exact 경로에서 개선 우세

3-8. 데이터 현황 시각화 차트

차트	핵심 메시지
Data Funnel	원본 8,110행에서 모델 유효 표본 5,874행으로 수렴하는 과정을 확인
Feature Coverage	핵심 변수와 F1/F2의 커버리지 분포를 확인
Core Feature Boxplot	`age`(나이), `HE_BMI`(BMI), `HE_wc`(허리둘레), `HE_glu`(공복 혈당) 분포 범위를 직관적으로 확인

---

4. 데이터 전처리(데이터 정리) 과정

"전처리"는 모델이 잘 배우도록 데이터를 정리하는 과정입니다.

순서	한 일	설명
1	성인만 남김	19세 이상만 사용
2	라벨 변환	당뇨/비당뇨 2가지로 단순화
3	결측 처리	빈칸(결측값)을 보완
4	표준화	값 크기를 비슷한 기준으로 맞춤
5	파생 피처 추가	허리-키 비율 등 새 정보 생성
6	SMOTE	당뇨 데이터가 적을 때 균형 보정

표준화 vs 정규화, 왜 표준화를 선택했나?

방법	의미	이번 선택
정규화	값을 0~1 범위로 맞춤	미선택
표준화	평균 0, 표준편차 1로 맞춤	**선택**

선택 이유: 이번에 쓴 KNN 같은 모델은 거리 계산을 많이 쓰기 때문에, 표준화가 안정적이었습니다.

---

5. Train / Validation / Test 나누기

데이터 묶음	비율	역할
Train	70%	모델 학습
Validation	10%	기준점(임계값) 조정
Test	20%	최종 성능 평가

쉽게 말해,

- **Train**: 공부용
- **Validation**: 모의고사
- **Test**: 최종 시험

---

6. 어떤 모델을 비교했고, 왜 이 모델을 골랐나?

6-1. 비교한 모델

분류	모델
선형	LogisticRegression, SGDClassifier
트리/앙상블	RandomForest, GradientBoosting, AdaBoost
거리/마진	KNN, SVM
신경망	MLPClassifier

6-2. 최종 선택 결과

두 실험 모두 **KNN**이 가장 좋은 점수를 얻었습니다.

실험	최종 모델	핵심 하이퍼파라미터
혈당 포함	KNN	`n_neighbors=3`, `weights=distance`, `p=2`
혈당 미포함	KNN	`n_neighbors=3`, `weights=distance`, `p=2`

6-3. 하이퍼파라미터(세부 설정) 선택 과정

- 여러 값 조합을 자동으로 시험해보는 방식(Grid Search)으로 비교
- 점수 기준: `balanced_recall`
  (정확도 + 환자 잘 찾는 능력(Recall)을 같이 반영)

---

7. 성능 결과 (숫자)

7-1. 핵심 지표 비교

지표	혈당 포함(기본+ `HE_glu`)	혈당 미포함(기본만)
Accuracy	0.8368	0.6675
Precision	0.4516	0.2267
Recall	0.8284	0.6036
F1	0.5846	0.3296
ROC-AUC	0.8608	0.6565

7-2. 왜 Accuracy만 보면 안 되나?

의료 문제에서는 “진짜 환자를 놓치지 않는 것”이 중요합니다.
그래서 **Recall**을 특히 중요하게 봤습니다.

지표	의미	왜 중요한가
Accuracy	전체 정답 비율	참고용
Precision	당뇨라고 한 것 중 진짜 비율	경고 정확도
Recall	실제 당뇨를 얼마나 잘 찾는지	의료에서 매우 중요
F1	Precision/Recall 균형	종합 판단

---

8. Confusion Matrix(예측 결과 요약표)

실험	TN	FP	FN	TP
혈당 포함	880	170	29	140
혈당 미포함	731	348	67	102

해석:

- **FN(놓친 환자)**가 적을수록 의료에 유리합니다.
- 혈당 포함 모델이 FN이 더 적어서 더 안전한 편입니다.

---

9. 어떤 모델이 의료 문제에 더 맞나?

결론: **혈당 포함 KNN 모델**이 더 적합합니다.

이유:

1. Recall이 더 높음 (환자를 더 잘 찾음)
2. ROC-AUC가 더 높음 (전체 구분 능력이 좋음)
3. Confusion Matrix에서 FN이 더 적음 (놓치는 환자 감소)

---

10. 앱 구현 시 전체 컬럼이 다 필요한가?

결론: **아니요. 핵심 입력만 필요합니다.**

구분	항목(변수)	설명
앱에서 직접 입력	성별(`sex`), 나이(`age`), 키(`height_cm`), 몸무게 (→ `HE_BMI` 계산), 허리둘레(`HE_wc`)	사용자가 화면에서 직접 입력
앱에서 선택 입력	혈당(`HE_glu`)	입력하면 혈당 포함 모델 사용
앱 내부 계산	BMI(`HE_BMI`)	키/몸무게로 앱에서 계산 후 서버 전송
서버 내부 계산	`HE_whr(허리-신장 비율)`	`HE_wc(허리둘레)` / `HE_ht(키)`
서버 내부 계산	`HE_bmi_wc(BMI×허리 보정)`	`HE_BMI(BMI)` × (`HE_wc(허리둘레)` /100)

> 운영 입력 정책: `HE_wc(허리둘레)` 는 본 앱에서 **필수 입력**으로 유지합니다.

---

11. 그림으로 보는 결과 (이미지 중심)

Figure 1. 테스트 지표 비교

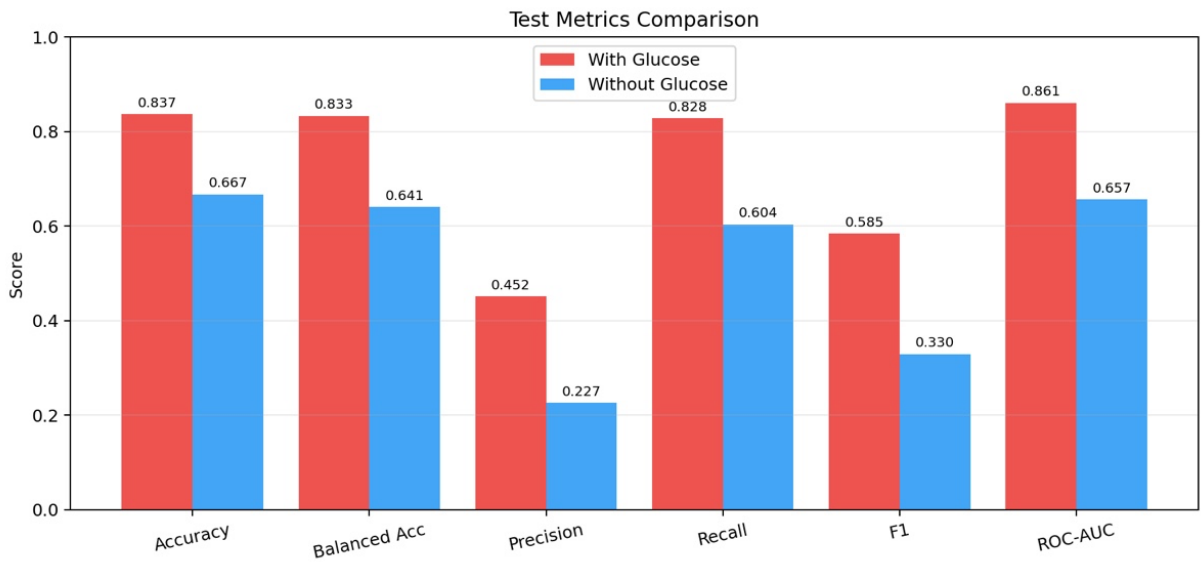

- 이 차트는 두 시나리오(혈당 포함/미포함)의 핵심 성능 지표를 한 번에 비교합니다.
- X축: 지표 종류(Accuracy, Precision, Recall, F1, ROC-AUC)

- Y축: 점수(0~1)
- 해석 포인트: 막대가 **높을수록 성능이 좋음**. 대부분 지표에서 혈당 포함 막대가 더 높습니다.

Figure 2. CV 점수 및 임계값 비교

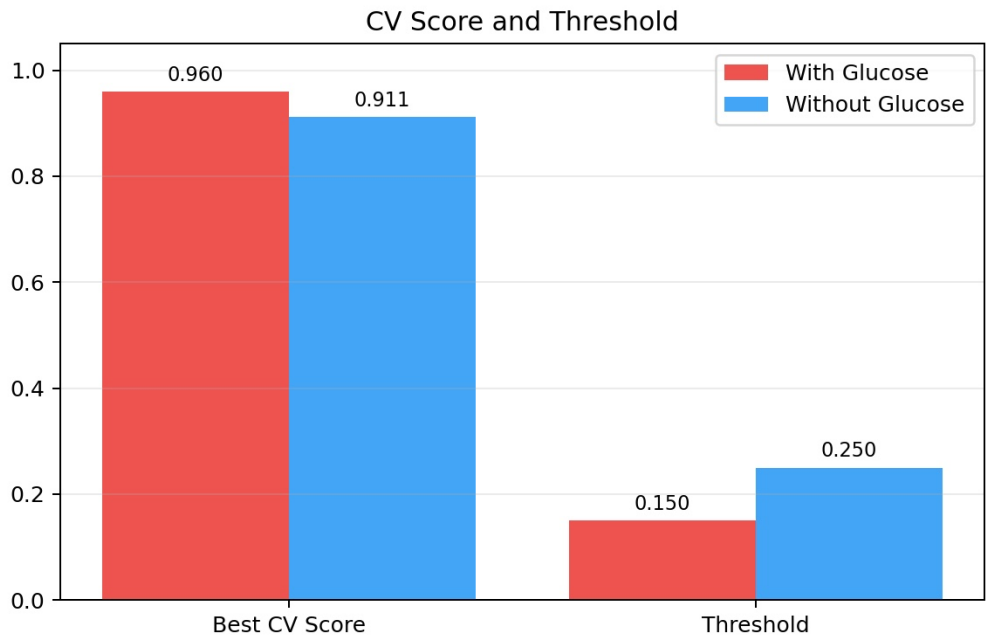

- 이 차트는 모델 선택에 사용된 교차검증 점수와 최종 임계값(threshold)을 비교합니다.
- X축: `Best CV Score`, `Threshold`
- Y축: 값(0~1)
- 해석 포인트: CV 점수는 **높을수록 좋고**, Threshold는 분류 경계값으로 높고 낮음 자체보다 운영 목적(민감도/정밀도)에 따라 의미가 달라집니다.

Figure 3. 레이더 차트(종합 성능)

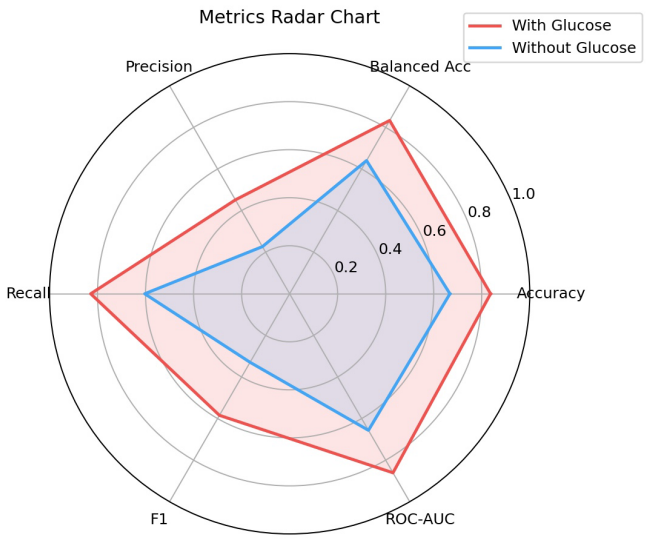

- 이 차트는 여러 지표를 원형으로 동시에 보여주는 종합 비교 그래프입니다.
- 각 축(방사형 축): Accuracy, Balanced Accuracy, Precision, Recall, F1, ROC-AUC
- 중심에서 바깥쪽으로 갈수록 점수가 큼(0→1)
- 해석 포인트: 면적이 넓고 바깥쪽일수록 전반 성능이 좋습니다. 혈당 포함 모델의 면적이 더 큽니다.

Figure 4. Confusion Matrix 비교

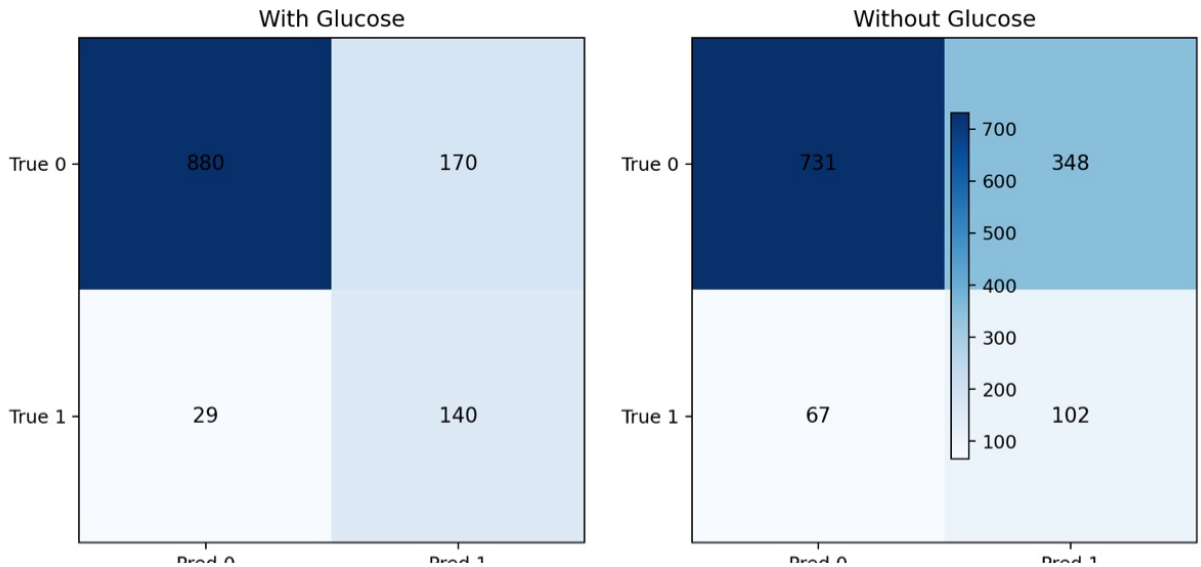

- 이 차트는 정답/오답을 2x2 표로 보여줍니다.
- X축: 모델 예측값(Pred 0, Pred 1), Y축: 실제값(True 0, True 1)
- 셀 의미: TN(정상 맞춤), FP(정상을 당뇨로 예측), FN(당뇨를 정상으로 놓침), TP(당뇨 맞춤)

- 해석 포인트: 의료 관점에서는 **FN이 낮을수록 유리**합니다. 혈당 포함 모델의 FN이 더 낮습니다.

Figure 5. ROC Curve 비교

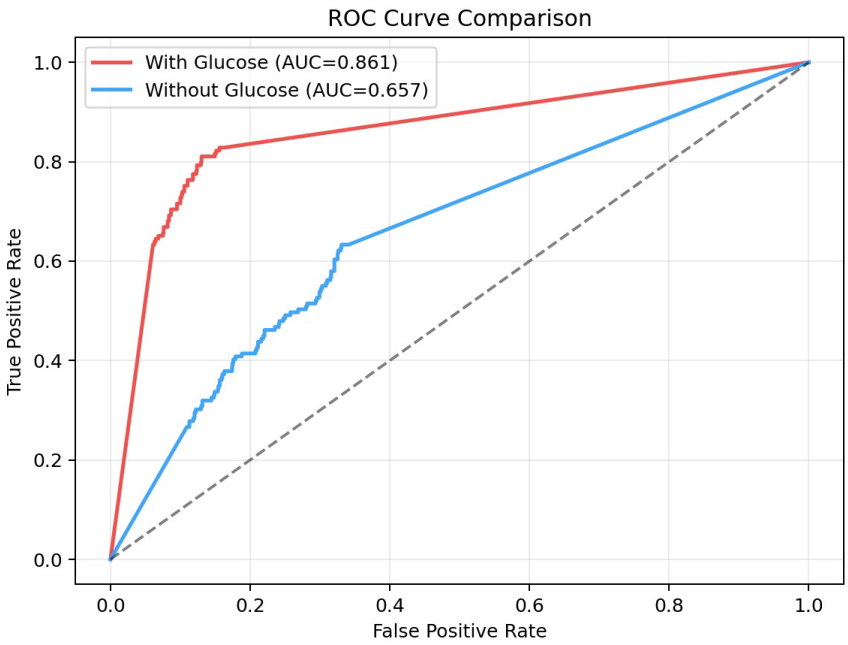

- 이 차트는 임계값을 바꿀 때 모델의 구분 능력이 어떻게 변하는지 보여줍니다.
- X축: FPR(False Positive Rate, 거짓 양성 비율)
- Y축: TPR(True Positive Rate, 실제 양성 탐지율 = Recall)
- 해석 포인트: 곡선이 **왼쪽 위에 가까울수록 좋고**, AUC 값이 **높을수록 좋습니다**.

Figure 6. 피처 수 비교

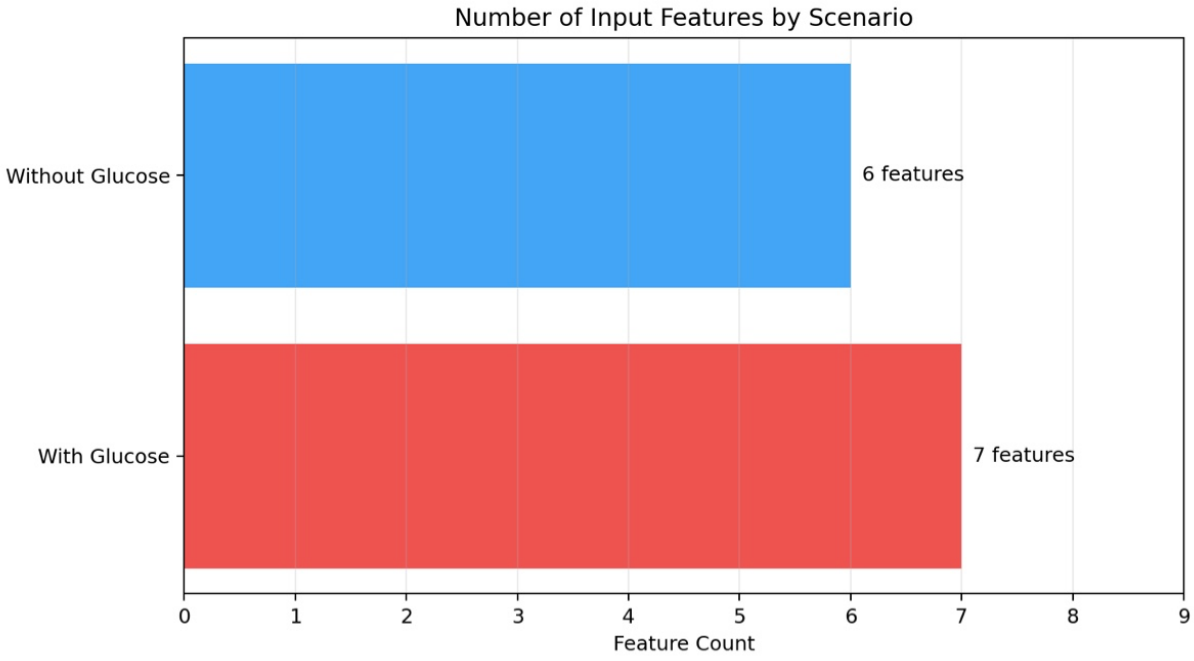

- 이 차트는 시나리오별 입력 피처 개수를 비교합니다.
- X축: 피처 개수
- Y축: 시나리오(혈당 포함/미포함)
- 해석 포인트: 혈당 포함 시나리오가 피처 1개(`HE_glu`) 더 많습니다.

Figure 7. Precision/Recall/F1 비교

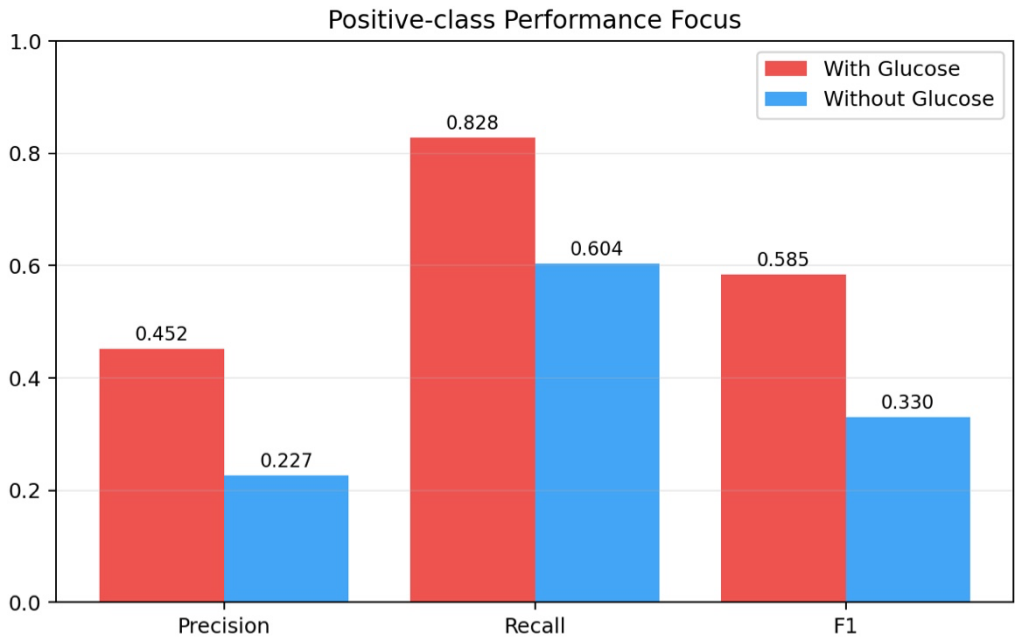

- 이 차트는 양성 클래스(당뇨) 중심 지표만 따로 비교합니다.

- X축: Precision, Recall, F1
- Y축: 점수(0~1)
- 해석 포인트: 막대가 **높을수록 좋음**. 특히 Recall 차이를 통해 환자 탐지 능력 차이를 확인할 수 있습니다.

Figure 8. 오류 유형(FP/FN) 비교

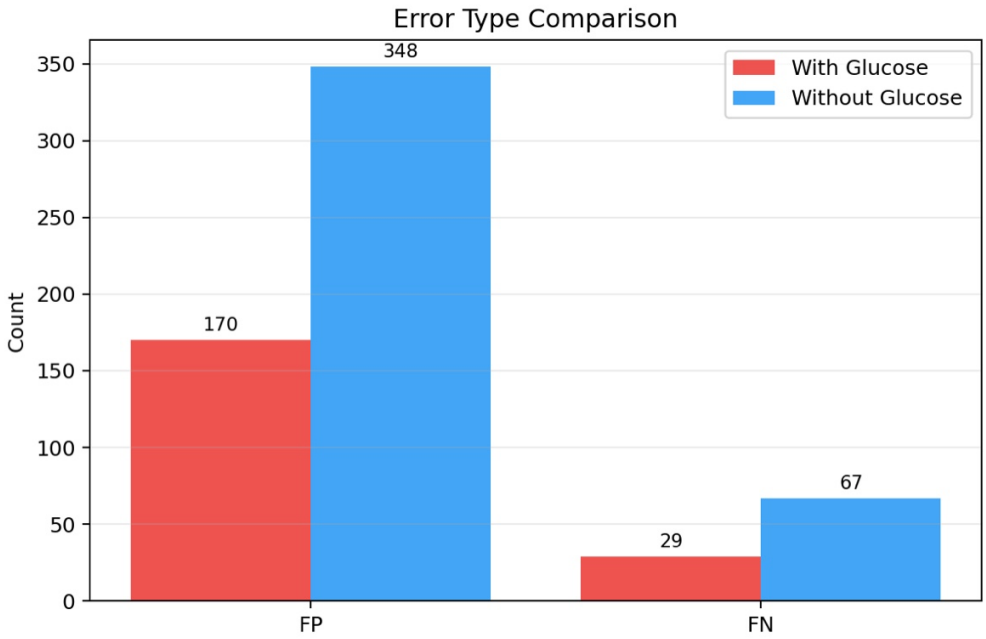

- 이 차트는 모델이 만든 두 가지 핵심 오류(FP, FN) 개수를 비교합니다.
- X축: 오류 유형(FP, FN)
- Y축: 오류 개수(건수)
- 해석 포인트: 의료 선별에서는 FN(환자 놓침)을 줄이는 것이 중요합니다. **막대가 낮을수록 더 바람직**합니다.

---

12. 재현(다시 실행) 방법

```
cd fastapi
source .venv/bin/activate

# 혈당 포함 모델 학습
python train_knhanes.py --with-glucose --feature-eng --poly --smote --score-by balanced_recall --save

# 혈당 미포함 모델 학습
python train_knhanes.py --feature-eng --poly --smote --score-by balanced_recall --save
```

데이터 파일 위치:

- `fastapi/resources/data/HN19_ALL.sav`

---

13. 운영 시나리오 시뮬레이션 (현재 앱 로직)

13-1. 용어 정리

용어	정의
`glu_exact`	`HE_glu(공복 혈당)` 을 연속값(정밀값)으로 입력한 경우
`glu_binned`	혈당 구간값(midpoint)으로 입력한 경우
`no_glu`	`HE_glu(공복 혈당)` 미입력
`blend`	혈당 의존도 완화를 위한 확률 혼합: `0.55 * no_glu + 0.45 * glu`

13-2. 시뮬레이션 결과 표 (`resources/simulation/simulation_summary.csv`)

시나리오	Accuracy	Precision	Recall	F1	ROC-AUC	FP	FN
glu_exact	0.9475	0.7526	0.9108	0.8242	0.9444	47	14
glu_binned	0.8590	0.4877	0.8854	0.6290	0.9116	146	18
no_glu	0.9020	0.5923	0.8790	0.7077	0.9156	95	19
blend_exact	0.8942	0.5620	0.9809	0.7146	0.9840	120	3
blend_binned	0.8564	0.4843	0.9809	0.6484	0.9783	164	3

13-3. 해석 요약

관점	해석
최고 종합 성능	`glu_exact` 가 Accuracy/F1에서 가장 우수
혈당 구간 입력	`glu_binned` 는 정밀 입력 대비 정보 손실 존재
FN 최소화 운영	`blend` 는 FN 감소에 유리하지만 FP 증가 트레이드오프 존재

13-4. 차트

---

14. F1~F2 사전 검증 결과 (추가 피처 플랜)

14-1. 플랜 피처 매핑 표

플랜 피처	데이터 변수(한글)	반영 상태
F1 가족력	`HE_DMfh1(부 당뇨 진단력)`, `HE_DMfh2(모 당뇨 진단력)`, `HE_DMfh3(형제자매 당뇨 진단력)`	시뮬레이션 매핑 완료
F2 고혈압/혈압약	`DI1_dg(고혈압 의사진단)`, `HE_HPdr(검진당일 혈압약 복용)`, `HE_HP(고혈압 유병)`	시뮬레이션 매핑 완료

14-2. F1/F2 분리(Ablation) 포함 결과 표 (`resources/simulation/feature_plan_simulation_summary.csv`)

시나리오	optional mode	glucose mode	Accuracy	Precision	Recall	F1	ROC-AUC	FP	FN
base_no_glu	none	none	0.7219	0.2830	0.6095	0.3865	0.6974	261	66
opt1_no_glu	f1	none	0.7287	0.2984	0.6568	0.4104	0.7211	261	58
opt2_no_glu	f2	none	0.7134	0.2801	0.6331	0.3884	0.6955	275	62
opt12_no_glu	f12	none	0.7245	0.2817	0.5917	0.3817	0.6852	255	69
base_glu_binned	none	binned	0.8673	0.5243	0.8284	0.6422	0.8892	127	29
opt1_glu_binned	f1	binned	0.8690	0.5283	0.8284	0.6452	0.8875	125	29
opt2_glu_binned	f2	binned	0.8741	0.5399	0.8402	0.6574	0.8901	121	27
opt12_glu_binned	f12	binned	0.8648	0.5182	0.8402	0.6411	0.8873	132	27
base_glu_exact	none	exact	0.8818	0.5586	0.8462	0.6729	0.8995	113	26
opt1_glu_exact	f1	exact	0.8801	0.5551	0.8343	0.6667	0.8983	113	28
opt2_glu_exact	f2	exact	0.8920	0.5868	0.8402	0.6910	0.9042	100	27
opt12_glu_exact	f12	exact	0.8665	0.5219	0.8462	0.6456	0.8965	131	26

14-3. 해석 요약

구간	해석
혈당 미입력(`none`)	`F1` 단독은 Recall(+0.0473)·FN(-8) 개선. `F2` 는 Recall 소폭 개선이나 FP 증가. `F1+F2` 동시 적용은 Recall/FN 악화로 비권장
혈당 구간(`binned`)	`F2` 단독이 Accuracy/Precision/Recall/F1 모두 개선(대표 우세). `F1+F2` 는 Recall만 개선되고 Accuracy/Precision 하락
혈당 정밀(`exact`)	`F2` 단독은 Accuracy/Precision/F1 개선, Recall은 소폭 하락(-0.0060). `F1` 단독과 `F1+F2` 동시 적용 이득은 제한적

14-4. 차트

---

15. 적용 검토 결과 및 향후 계획

항목	검토 기준	본 보고서 기준 정리
심플 탭	입력 부담 최소화	현행 유지(변경 없음)
상세 탭	성능 개선 + 사용자 수용성	조건부 확장 검토(F1, F2 중심)
F1 가족력	no_glu 구간 Recall/FN 개선 확인, glu 입력군 이득 제한	조건부 후보(혈당 미입력 경로 우선)
F2 고혈압/혈압약	binned/exact 구간에서 Accuracy·F1 개선 재현	우선 검토 후보(상세 탭 1순위)
허리둘레 입력	사용자 입력 가능성 및 모델 안정성	필수 입력 유지
운영 모니터링	Recall/FN/FP 추적	분기별 성능 점검

---

16. 추가 재현 명령 (시뮬레이션)

```python
cd fastapi
source .venv/bin/activate

# 운영 시나리오 시뮬레이션 (blend 포함)
python simulate_optional_input_cases.py

# 플랜 피처(F1~F2) 포함/미포함 시뮬레이션
python simulate_feature_plan_cases.py
```

---

17. 요약 및 향후 반영 방향

항목	요약
제품 구성	심플 탭은 유지하고, 상세 탭에서 확장 항목을 단계적으로 검토
입력 정책	HE_wc(허리둘레) 는 필수 입력으로 유지
확장 우선순위	F2(고혈압/혈압약) 단독 우선 → F1(가족력)은 조건부 검토
운영 방향	기본 경로를 유지하면서, 확장 경로는 검증 결과에 따라 반영

17-1. 단계별 반영안(초안)

1. **Phase 1**: 상세 탭 확장 경로에 F2 단독 반영 검토(특히 binned/exact), Recall·FP·FN 추적
2. **Phase 2**: F1은 혈당 미입력 경로 중심으로 조건부 반영 검토 및 재평가

17-2. 성능 검토 기준

구분	기준(검토 지표)
성능 개선 판단	상세 탭 확장 후 Recall 개선 또는 FN 감소 확인
주의 신호	혈당 정밀 입력군 성능 저하 반복 또는 오탐(FP) 급증

---

18. API 더미 테스트 케이스(실응답)

서버 정책(F2 우선, F1 조건부, KNHANES 외 자동 제외) 검증을 위해 `/predict` 를 실제 호출했다.

- 실행 일시: 2026-02-21
- 실행 환경: `uvicorn app.main:app --host 127.0.0.1 --port 8000`
- 공통: 응답의 `chart_image_base64` 는 표에서 생략

18-1. 케이스 요약 표

케이스	목적	HTTP	prediction / probability	used_model	정책 확인 포인트
case1_knhanes_no_glu_f1f2	혈당 미입력 + F1/F2 동시 입력	200	1 / 1.0	KNHANES 혈당 미포함	`input` 에 `family_history_dm` , `htn_or_med` 모두 포함
case2_knhanes_glu_f1f2	혈당 입력 + F1/F2 동시 입력	200	1 / 0.55	KNHANES 블렌드	`input` 에서 `family_history_dm` 제외, `htn_or_med` 유지
case3_knhanes_glu_f2_only	혈당 입력 + F2만 입력	200	1 / 0.1607	KNHANES 블렌드	`input` 에 `htn_or_med` 만 포함
case4_pima_with_f1f2	Pima 경로 + F1/F2 입력	200	0 / 0.4062	AdaBoost (혈당 포함)	`input` 에서 F1/F2 자동 제외
case5_range_error	범위 오류(혈당 300)	400	-	-	범위 검증 에러 메시지 확인
case6_minimal_no_glu	최소 입력(혈당 미입력)	200	1 / 1.0	KNHANES 혈당 미포함	기본 경로 정상 응답 확인

18-2. 실응답 핵심(JSON 발췌)

case2_knhanes_glu_f1f2 (혈당 입력 + F1/F2 동시 입력)

```
{
  "prediction": 1,
  "probability": 0.55,
  "used_model": "KNHANES 블렌드 (위험인자 55% + 혈당 45%)",
  "input": {
    "glucose": 95.0,
    "bmi": 28.0,
    "age": 47.0,
    "waist_cm": 94.0,
```

```
      "sex": 1.0,
      "height_cm": 170.0,
      "htn_or_med": 0.0
    }
  }
```

검증: 요청에는 가족력 을 포함했지만 응답 `input` 에서 제외되어 서버 정책이 적용됨.

case4_pima_with_f1f2 (Pima 경로 + F1/F2 입력)

```
{
  "prediction": 0,
  "probability": 0.4062,
  "used_model": "AdaBoost (혈당 포함)",
  "input": {
    "pregnancies": 2.0,
    "glucose": 95.0,
    "bmi": 28.0,
    "age": 47.0
  }
}
```

검증: Pima 경로에서는 `family_history_dm` , `htn_or_med` 가 자동 제외됨.

case5_range_error (혈당 범위 오류)

```
{
  "detail": "혈당(glucose) 값은 44.0 ~ 199.0 범위여야 합니다."
}
```

검증: 입력값 범위 검증이 정상 동작함.